Lern-Nugget: Sigmoid als Spezialfall von Softmax

🎯 Ziel

Den eleganten Zusammenhang zwischen Sigmoid und Softmax verstehen - warum Sigmoid nur ein Spezialfall von Softmax für binäre Klassifikation ist!

🤔 Das Problem: Zwei scheinbar verschiedene Funktionen

Sigmoid (binäre Klassifikation): - σ(z) = 1/(1 + e^(-z)) - Ausgabe: Ein Wert zwischen 0 und 1, der als Modellwahrscheinlichkeit für die positive Klasse interpretiert wird - Verwendung: "Hund oder Katze?", "Spam oder nicht?"

Softmax (Multi-Klassen-Klassifikation): - softmax(z_i) = e^(z_i) / Σ(e^(z_j)) - Ausgabe: Eine Verteilung von Modellwahrscheinlichkeiten über die Klassen - Verwendung: "Hund, Katze, oder Vogel?", "0, 1, 2, ..., 9?"

Frage: Sind das wirklich verschiedene Funktionen? 🤷

Die Ausgaben lassen sich als Wahrscheinlichkeiten interpretieren, sind dadurch aber nicht automatisch gut kalibriert oder zuverlässig.

🔍 Der Schlüssel: Softmax mit 2 Klassen

Gegeben: Zwei Klassen mit Logits z_1 und z_2

Softmax berechnen: - P(Klasse 1) = e^(z_1) / (e^(z_1) + e^(z_2)) - P(Klasse 2) = e^(z_2) / (e^(z_1) + e^(z_2))

Schritt 1: Trick anwenden

Dividiere Zähler und Nenner durch e^(z_2):

P(Klasse 1) = e^(z_1) / (e^(z_1) + e^(z_2)) = (e^(z_1)/e^(z_2)) / ((e^(z_1) + e^(z_2))/e^(z_2)) = e^(z_1-z_2) / (e^(z_1-z_2) + 1)

Definiere: z = z_1 - z_2 (der "relative" Logit)

P(Klasse 1) = e^z / (e^z + 1) = e^z / (e^z + 1) · e^(-z)/e^(-z) = 1 / (1 + e^(-z))

🎉 Überraschung: Das ist Sigmoid!

P(Klasse 1) = σ(z_1 - z_2) = 1/(1 + e^(-(z_1-z_2)))

Was bedeutet das?

1. **Sigmoid ist mathematisch äquivalent zu Softmax für 2 Klassen, wenn es auf die Differenz der beiden Logits angewendet wird.**
2. **z = z_1 - z_2** ist der Unterschied zwischen den Klassen-Logits

3. **P(Klasse 2) = 1 - P(Klasse 1)** automatisch erfüllt

📊 Konkrete Zahlenbeispiele

Beispiel 1: Klare Entscheidung

Logits: $z_1 = 2$, $z_2 = -1$ - **Softmax:** - P(Klasse 1) = $e^2/(e^2 + e^{-1}) = 7.39/(7.39 + 0.37) \approx 0.95$ - P(Klasse 2) = $e^{-1}/(e^2 + e^{-1}) = 0.37/(7.39 + 0.37) \approx 0.05$ - **Sigmoid:** $\sigma(2-(-1)) = \sigma(3) = 1/(1 + e^{-3}) \approx 0.95$ ✓

Beispiel 2: Unklare Entscheidung

Logits: $z_1 = 0.5$, $z_2 = 0.3$ - **Softmax:** - P(Klasse 1) = e^0.5/(e^0.5 + e^0.3) = 1.65/(1.65 + 1.35) ≈ 0.55 - P(Klasse 2) = e^0.3/(e^0.5 + e^0.3) = 1.35/(1.65 + 1.35) ≈ 0.45 - **Sigmoid:** $\sigma(0.5-0.3) = \sigma(0.2) = 1/(1 + e^{-0.2}) \approx 0.55$ ✓

🧠 Intuitive Interpretation

Was sagt $z = z_1 - z_2$?

z > 0: Klasse 1 ist "stärker" → P(Klasse 1) > 0.5 **z < 0:** Klasse 2 ist "stärker" → P(Klasse 1) < 0.5
z = 0: Beide gleich stark → P(Klasse 1) = 0.5

Praktische Bedeutung:

Bei binärer Klassifikation genügt ein Logit. - Statt z_1 und z_2 zu berechnen - Berechnen wir direkt z = "Unterschied der Klassen-Scores" - Sigmoid gibt uns P(Klasse 1) = σ(z) - P(Klasse 2) = 1 - σ(z) ergibt sich automatisch

🏗️ Implementierung: Von Softmax zu Sigmoid

Multi-Klassen Netzwerk:

```
Input → Hidden → [z₁, z₂, z₃, z₄] → Softmax → [p₁, p₂, p₃, p₄]
```

Binäres Netzwerk mit zwei Logits:

```
Input → Hidden → [z₁, z₂] → Softmax → [p₁, p₂]
```

Binäres Netzwerk (elegant):

```
Input → Hidden → z → Sigmoid → p₁
                             (p₂ = 1-p₁)
```

🎯 Wichtige Erkenntnisse

1. Mathematische Verbindung

- Sigmoid ist nicht "anders" als Softmax

- Mit einem Logit $z = z_1 - z_2$ lässt sich dieselbe binäre Verteilung ausdrücken
- Eine Ausgabeeinheit statt zwei kann die letzte Schicht vereinfachen; wie viele Modellparameter das spart, hängt von der Schicht ab

2. Praktische Konsequenzen

- **Binäre Klassifikation:** Ein Logit mit Sigmoid ist eine gängige Möglichkeit; zwei Logits mit Softmax sind ebenfalls möglich
- **Mehrklassen-Klassifikation:** Softmax ist üblich, wenn genau eine von mehreren Klassen gewählt wird
- **Mehrfachlabels:** Wenn mehrere Klassen gleichzeitig zutreffen können, werden häufig einzelne Sigmoid-Ausgaben verwendet
- Beim Wechsel zwischen diesen Aufgaben ändern sich die Ausgabeform und meist auch die passende Loss-Funktion.

3. Loss-Funktionen

- **Binary Cross-Entropy:** -[y log σ(z) + (1-y) log(1-σ(z))]
- **Categorical Cross-Entropy:** -Σ y_i log(softmax_i(z))
- Bei zwei Klassen, One-Hot-Labels und übereinstimmenden Wahrscheinlichkeiten ergeben beide pro Beispiel denselben Loss.

🎲 Übung: Verständnis testen

Gegeben: Ein Netzwerk klassifiziert E-Mails als "Spam" oder "Ham"

Szenario A: Zwei Output-Neuronen mit Softmax - Output: [2.1, -0.3] → Softmax → [0.92, 0.08]

Szenario B: Ein Output-Neuron mit Sigmoid
- Output: z = ? → Sigmoid → 0.92

Frage: Welcher Wert z ergibt sich in Szenario B?

Lösung: - z = z_spam - z_ham = 2.1 - (-0.3) = 2.4 - σ(2.4) = 1/(1 + e^(-2.4)) ≈ 0.92 ✓

📝 Zusammenfassung

Kernbotschaft:

> Sigmoid ist Softmax für 2 Klassen. Statt zwei Logits z_1, z_2 zu berechnen, berechnen wir einen "relativen" Logit $z = z_1 - z_2$ und wenden Sigmoid darauf an.

Praktisch bedeutet das: - ✅ **Klarheit:** z ist die Differenz der beiden Klassen-Logits - ✅ **Einfachheit:** Für binäre Klassifikation genügt eine Ausgabe mit Sigmoid - ✅ **Verständnis:** Beide Funktionen sind Teil derselben mathematischen Familie

---

💡 **Tipp:** Der Zusammenhang zeigt, wie sich eine binäre Softmax-Ausgabe durch einen einzigen relativen Logit und Sigmoid ausdrücken lässt. Die ausgegebenen Modellwahrscheinlichkeiten sind

nicht automatisch kalibriert.